



FACULTAD DE CIENCIAS DE LA DOCUMENTACIÓN

UNIVERSIDAD COMPLUTENSE DE MADRID

Máster en Data Science, Big Data & Business Analytics

Trabajo Fin de MÁSTER

**Más Allá de la Predicción: Simulaciones para Entender el
Abandono en Salud Mental**

Alumna: Andrea Carolina Buenaño Vinueza

Barcelona, 11 de Septiembre del 2025

Índice

1. Introducción.....	4
2. Estado del arte y fundamentación teórica.....	5
2.1 Fundamentos de Ciencia de Datos: Predictores de Abandono (Churn) y Modelos de Simulación.....	5
2.2 Perspectiva sociológica: determinantes sociales del abandono, desigualdad, instituciones y redes de apoyo.....	6
2.3 Aprendizajes de estudios previos y justificación del enfoque de este TFM.....	7
3. Objetivos del estudio.....	8
3.1 Objetivo general.....	8
3.2 Objetivos específicos.....	9
3.3 Preguntas de investigación:.....	9
4. Dataset y preparación de datos.....	10
4.1. Procedencia y descripción del dataset.....	10
4.2 Variables clave y construcción de la variable “Churn”.....	10
4.3 Limitaciones encontradas (predictores dominantes, sesgos, calidad de datos).....	11
4.4 Transformaciones y preparación para el análisis.....	11
5. Metodología.....	12
5.1 Análisis exploratorio (EDA).....	12
5.1.1. Estadísticos descriptivos.....	13
5.1.2 Propiedades estadísticas.....	14
5.1.3 Variables categóricas.....	14
5.2 Cohortes y análisis descriptivo de abandono.....	15
5.2.1. Distribución inicial del abandono.....	15
5.2.3. Construcción de cohortes descriptivas.....	16
5.2.4. Resultados descriptivos por cohortes.....	16
5.3 Segmentación de usuarios mediante clustering.....	17
5.3.1. Preparación de los datos.....	17
5.3.2. Determinación del número de clusters.....	18
5.3.3. Resultados del clustering.....	18
5.4 Modelos explicativos exploratorios.....	19
5.4.1 Modelos predictivos y diagnóstico de viabilidad.....	20
5.4.2. Transición hacia un modelo explicativo.....	20
5.5 Simulación de estrategias de retención mediante A/B Testing.....	21
5.5.1 Resultados poblacionales de las simulaciones A/B.....	21
5.5.2 Diseño factorial 2 ⁴ : combinaciones de cambios.....	22
6.5 Dashboard de resultados: KPIs, visualizaciones y uso orientado a negocio.....	23

6.5.1 Diseño del dataset para el dashboard.....	23
6.5.2 Visualización final: estructura y propósito del dashboard.....	24
7. Discusión.....	25
8. Conclusiones y recomendaciones.....	26
9. Limitaciones y trabajo futuro.....	27
ANEXOS:.....	30
Anexo 1. Descarga de datos y EDA inicial.....	30
Anexo 2. Creación de churn y cohortes descriptivas.....	30
Anexo 3. Segmentación de clientes (Clustering).....	30
Anexo 4. Modelización y evaluación del churn.....	30
Anexo 5. Análisis explicativo con regresión logística.....	30
Anexo 6. Simulación de experimentos A/B.....	30
Anexo 7. Preparación de datos para dashboard en Tableau.....	30

1. Introducción

En un comunicado de prensa del 2 de septiembre de este año, la Organización Mundial de la Salud (OMS) informó que más de mil millones de personas viven con algún trastorno mental, lo que convierte a estas afecciones en una de las principales causas de discapacidad y pérdidas económicas a nivel mundial (Organización Mundial de la Salud, 2025). La OMS también presentó los hallazgos de dos nuevos informes que, aunque reconocen ciertos avances, subrayan que la inversión y los servicios disponibles siguen siendo insuficientes.

Ante la creciente necesidad de servicios de salud mental accesibles y sostenibles, las intervenciones por Internet han surgido como una alternativa prometedora. La literatura científica respalda su eficacia, señalando que estas herramientas no solo mantienen estándares de calidad y generan resultados clínicos positivos, sino que también permiten reducir costos de manera significativa (Gratzer & Khalid-Khan, 2015). No obstante, a pesar de su efectividad comprobada, las terapias digitales de salud mental suelen enfrentar críticas por sus bajos niveles de participación y retención. Persisten dudas relevantes sobre cómo interactúan los usuarios con estas plataformas, cuál es la mejor manera de medir el compromiso, y qué factores podrían fomentar una mayor participación. Diversos estudios han documentado las altas tasas de abandono, tanto en intervenciones digitales (Baumel et al., 2019) como en terapias presenciales (Ong et al., 2018). Este fenómeno limita la efectividad de las intervenciones, eleva los costes asociados y puede agravar los problemas de salud mental.

Desde esta realidad —y considerando tanto la urgencia social como el potencial impacto en modelos de negocio sostenibles— creemos fundamental comprender y abordar el abandono en programas de salud mental. Hemos identificado que este desafío presenta similitudes con los problemas de retención de clientes en otros sectores, como el marketing digital o los servicios por suscripción. No proponemos tratar a los pacientes como simples clientes, sino aplicar de forma ética y contextualizada las metodologías de análisis y predicción que ya se utilizan con éxito en otros ámbitos. En este caso, el valor de anticipar y reducir el abandono no reside únicamente en los beneficios económicos: se traduce directamente en una mejora del bienestar de las personas y en una mayor eficiencia de los sistemas de salud. La ciencia de datos, cuando se aplica con responsabilidad ética y sensibilidad social, ofrece herramientas poderosas para detectar patrones de abandono y diseñar estrategias de retención basadas en evidencia.

Este Trabajo Fin de Máster se inició bajo el título provisional “**Predicción de abandono en programas de salud mental y evaluación de estrategias de retención mediante simulación A/B**”. El objetivo era construir un modelo predictivo de *churn* a partir de un conjunto de datos amplio (50.000 registros) y, posteriormente, evaluar estrategias de retención mediante simulación. Sin embargo, durante el desarrollo del proyecto se identificaron limitaciones importantes en la calidad del dataset, especialmente la presencia de predictores casi deterministas (como *Mental_Health_Condition* y *Consultation_History*), lo que dificultaba seriamente la

construcción de un modelo robusto y generalizable. Insistir en un enfoque puramente predictivo habría generado resultados poco útiles, tanto desde una perspectiva académica como práctica. Ante esta situación, y en línea con el enfoque aplicado del máster, se optó por redefinir el título y el planteamiento del trabajo, hacia: **“Más Allá de la Predicción: Simulaciones para Entender el Abandono en Salud Mental”**.

Este cambio no implica una ruptura con la propuesta original, sino una adaptación metodológica que mantiene los objetivos centrales: estudiar el abandono y diseñar estrategias de retención. La diferencia está en el enfoque, que recurre a técnicas más adecuadas para este contexto, como el análisis de cohortes, la segmentación de usuarios y la simulación de intervenciones tipo A/B. El trabajo tiene una doble motivación. Por un lado, aportar evidencia empírica y metodológica sobre cómo analizar el abandono en salud mental cuando los datos no permiten aplicar modelos predictivos convencionales. Por otro, generar resultados útiles para instituciones y profesionales, presentados de forma clara a través de un dashboard interactivo que facilita la interpretación de las simulaciones y la comprensión de los perfiles de riesgo.

2. Estado del arte y fundamentación teórica

2.1 Fundamentos de Ciencia de Datos: Predictores de Abandono (Churn) y Modelos de Simulación

El análisis del abandono de usuarios (*churn*) ha sido ampliamente utilizado en sectores como las telecomunicaciones y el comercio electrónico, y más recientemente se ha aplicado al ámbito de la salud mental digital. Las DMHI (intervenciones digitales de salud mental, por sus siglas en inglés), a pesar de su eficacia clínica demostrada, enfrentan un problema persistente de bajo *engagement* y retención. No obstante, los estudios también muestran una gran variabilidad en el uso: algunos usuarios apenas interactúan con la plataforma, mientras que otros se convierten en superusuarios con niveles de adherencia elevados (Boucher & Raiker, 2024)

En el campo de la Estadística, la predicción temprana del abandono ya ha sido objeto de estudio. En el ámbito educativo, Hjorth et al. (2016) emplearon modelos estadísticos tradicionales, principalmente regresión logística, para analizar la relación entre salud mental y abandono escolar en una cohorte con seguimiento de 4,8 años. Sus resultados evidenciaron limitaciones que también afectan al estudio del abandono en salud mental: la falta de consenso en la definición de abandono, la alta dependencia de variables contextuales (como salud mental autoinformada, nivel educativo o ingreso parental) y la dificultad para generalizar los modelos a otros contextos sociales y educativos (Hjorth et al., 2016) Estos mismos problemas surgieron en este TFM: al intentar predecir con Machine Learning, encontramos definiciones inconsistentes de “abandono”, una fuerte dependencia de determinadas variables y obstáculos para construir modelos con capacidad de generalización

Frente a estas limitaciones, la literatura ha explorado la simulación como estrategia alternativa. El modelado basado en agentes (ABM) se ha utilizado para estudiar cómo la depresión afecta dinámicas colectivas como la permanencia académica, permitiendo observar patrones de abandono emergentes a partir de interacciones individuales (Abdelhamid, et al., 2016). Asimismo, en el campo de la salud conductual se han desarrollado métodos de optimización de políticas personalizadas como DecompPI, que permiten evaluar intervenciones con datos históricos y recursos limitados, evitando la necesidad de ensayos clínicos extensivos en tiempo real (Baek et al., 2024). En síntesis, la literatura en ciencia de datos respalda la utilidad de integrar análisis exploratorio, segmentación y simulaciones para evaluar estrategias de retención cuando los modelos predictivos clásicos no resultan adecuados.

2.2 Perspectiva sociológica: determinantes sociales del abandono, desigualdad, instituciones y redes de apoyo

Desde la sociología, el abandono en programas de salud mental se entiende como un proceso condicionado por factores estructurales, institucionales y comunitarios. En esta línea, Kirkbride et al. (2024) identifican un conjunto de determinantes sociales —como la educación, el empleo, los ingresos, la exclusión, la discriminación y las condiciones de vida y trabajo— que aumentan la vulnerabilidad frente a problemas de salud mental y afectan, indirectamente, la continuidad en el tratamiento. Este enfoque no solo explica desigualdades, sino que propone una agenda de prevención y justicia social a lo largo del curso de vida.

Vinculado directamente al abandono, Firth et al. (2022) señalan que, si bien es común en intervenciones psicológicas para trastornos mentales frecuentes (con tasas estimadas entre el 20 % y 35 %), su relación con la privación socioeconómica no es concluyente y depende de cómo se mida dicha privación y del tipo de intervención. Además, destacan dos aspectos relevantes: la heterogeneidad en la forma de definir el abandono (por ejemplo, no iniciar el tratamiento vs. abandonarlo una vez empezado), y los posibles sesgos si no se diferencian adecuadamente el acceso digital de la participación activa (como completar un módulo vs. asistir a una sesión), ambos con implicaciones para la interpretación de desigualdades y el diseño de políticas.

Desde una perspectiva institucional, diversos estudios muestran que el abandono también está influido por cómo se organizan los servicios. Reneses et al. (2009), en un estudio en cuatro centros comunitarios, encontraron una tasa de abandono del 33,2 %, asociada al centro de atención, la rotación de terapeutas, la edad joven y el sexo masculino. De forma similar, Henzen et al. (2016) reportaron una tasa del 37,5 % en una unidad de crisis comunitaria, con mayor abandono durante los primeros días de seguimiento y entre personas jóvenes con diagnósticos de ansiedad o trastorno de personalidad. En contraste, las derivaciones desde hospitales o psiquiatras privados se asociaron con menor abandono, lo que subraya la importancia de los circuitos de derivación y la continuidad asistencial.

El contexto histórico también influye. Durante la pandemia de COVID-19, un estudio en clínicas comunitarias de India documentó que el miedo al contagio, las restricciones por cuarentena, la falta de acceso a medicación y la percepción de no necesitar tratamiento fueron motivos clave de abandono, con una tasa del 21 % (Sidana et al., 2023). Este estudio también resalta la variabilidad de definiciones en la literatura, lo que afecta la comparación entre investigaciones.

Por otro lado, un enfoque sociológico desde la educación también aporta evidencia útil. Hjorth et al. (2016), en un estudio longitudinal en Dinamarca, encontraron que una mala salud mental autoinformada aumentaba significativamente el riesgo de abandonar la formación profesional o universitaria, especialmente entre varones ($OR \approx 5,2$). Aunque este estudio no analiza terapias ni utiliza herramientas de inteligencia artificial, subraya que el abandono está profundamente vinculado con factores institucionales y de género, y que generalizar estos hallazgos a otros contextos debe hacerse con cautela.

Finalmente, la literatura sobre apoyo entre pares en salud mental muestra que las redes sociales y comunitarias pueden favorecer la vinculación y la continuidad, más allá de los resultados clínicos inmediatos. Según Lyons et al. (2021), estos dispositivos mejoran la participación y el afrontamiento, aunque sus efectos en síntomas clínicos, esperanza o empoderamiento son modestos o mixtos, y varían según el diseño de la intervención. Esto sugiere que el apoyo entre pares debe entenderse como un complemento —no un reemplazo— de la atención profesional.

En conjunto, esta perspectiva sociológica aporta tres ideas clave para este TFM: Primera, el abandono no es solo una decisión individual, sino un fenómeno contextual influido por factores sociales e institucionales; Segunda, la forma en que se define el abandono y se estructuran los servicios afecta directamente las tasas observadas; y Tercera, tanto las redes de apoyo como los circuitos de derivación pueden ser herramientas útiles para reducir el abandono, aunque su efectividad depende del diseño organizativo y las condiciones estructurales (Firth et al., 2021).

2.3 Aprendizajes de estudios previos y justificación del enfoque de este TFM

A partir de la revisión de estudios en estadística, ciencia de datos y sociología, este TFM identifica tres ideas clave para entender mejor el abandono en programas de salud mental y justificar el enfoque metodológico adoptado.

1. El abandono no significa lo mismo en todos los contextos: En intervenciones digitales, los niveles de participación varían mucho entre usuarios, por lo que es fundamental definir claramente qué se entiende por abandono y en qué momento ocurre (Boucher & Raiker, 2024). Además, factores como la organización del servicio o situaciones excepcionales, como la pandemia, también influyen en el abandono, ya sea por miedo, falta de acceso o cambios en los circuitos de atención (Sidana et al., 2023). Por eso, este

trabajo utiliza análisis de cohortes para distinguir entre quienes no inician, quienes abandonan temprano y quienes lo hacen en etapas posteriores.

2. El contexto social y la forma en que funciona el sistema de salud influyen en si alguien continúa o no con su tratamiento: La relación entre abandono y pobreza no es clara ni uniforme; varía según cómo se mida y qué tipo de intervención se analice (Firth et al., 2021). Además, existen múltiples motivos para abandonar: sentirse mejor, cambiar de institución, barreras económicas, efectos secundarios o experiencias negativas en el servicio (Velázquez et al., 2000). Este TFM, por tanto, no solo analiza *quién* abandona, sino también *por qué* y *en qué etapa del proceso*, agrupando a los usuarios según sus características.
3. Cuando no se puede predecir con precisión, simular escenarios puede ser una buena alternativa: cuando la predicción clásica no es suficiente, la simulación ofrece una alternativa útil. Aunque los modelos de inteligencia artificial han avanzado en predecir abandono temprano, aún enfrentan desafíos para generalizar resultados y definir con precisión el abandono (Bae et al., 2024). Frente a esto, se han desarrollado herramientas como DecomPI, que permiten simular escenarios de intervención con datos históricos y estimar el posible impacto sin necesidad de probarlos directamente en pacientes (Bae et al., 2024).

En consecuencia, este TFM adopta un enfoque híbrido: análisis de cohortes para medir retención con claridad, segmentación para identificar perfiles y causas de abandono, y simulación para evaluar el impacto potencial de distintas estrategias. Todos estos elementos se integran en un dashboard interactivo, diseñado para apoyar la toma de decisiones institucionales, combinando datos cuantitativos con una perspectiva organizativa y orientada a la equidad.

3. Objetivos del estudio

3.1 Objetivo general

El objetivo principal de este Trabajo Fin de Máster es analizar los factores que influyen en el abandono de programas de salud mental, utilizando técnicas de análisis de cohortes y segmentación de usuarios, y complementándolo con simulaciones de estrategias de retención mediante experimentos A/B. A diferencia de un enfoque centrado únicamente en predecir el abandono (churn), este trabajo propone un marco explicativo y aplicado, que permite tanto identificar perfiles de riesgo como estimar de forma anticipada el posible impacto de distintas intervenciones sobre la adherencia.

3.2 Objetivos específicos

1. Análisis exploratorio de datos (EDA): Examinar el conjunto de datos sobre salud mental para describir patrones generales de abandono, distribuciones de variables clave y relaciones entre factores individuales y sociales.
2. Segmentación de usuarios: Aplicar técnicas de *clustering* para identificar grupos diferenciados de usuarios, considerando su condición de salud mental, historial de consultas y características sociodemográficas.
3. Evaluación de predictores de abandono: Analizar estadísticamente la relación entre diversas variables explicativas (como el historial de atención, la condición mental o el nivel socioeconómico) y la probabilidad de abandono, destacando las limitaciones de los enfoques predictivos tradicionales.
4. Simulación de estrategias de retención mediante A/B Testing: Modelar diferentes escenarios de intervención sobre grupos de usuarios (cohortes) para estimar su impacto potencial en la retención, comparando condiciones que varían en términos de parámetros de comportamiento.
5. Desarrollo de un dashboard interactivo: Construir un panel visual en Tableau que integre los hallazgos del análisis de cohortes y las simulaciones A/B, con el objetivo de apoyar la toma de decisiones en contextos institucionales

3.3 Preguntas de investigación:

Para comprender mejor los factores que influyen en el abandono de programas de salud mental, con el fin de proponer herramientas analíticas y prácticas que ayuden a mejorar la retención de usuarios. Para ello, se plantean las siguientes preguntas de investigación, que orientan tanto el análisis de datos como el desarrollo metodológico:

1. ¿Qué factores individuales y sociales están más fuertemente asociados con el abandono en programas de salud mental, y cómo se manifiestan en los datos disponibles?
2. ¿Es posible identificar perfiles o grupos diferenciados de usuarios con mayor riesgo de abandono, que permitan orientar intervenciones más específicas y efectivas?
3. ¿Qué limitaciones presentan los modelos predictivos tradicionales (como regresión logística o Random Forest) en este tipo de contextos, y cómo estas limitaciones justifican el uso de un enfoque basado en cohortes y simulaciones?
4. ¿Qué efecto potencial tendrían distintas estrategias de retención, probadas a través de simulaciones tipo A/B, en la reducción de las tasas de abandono?
5. ¿Cómo puede un dashboard interactivo facilitar la comprensión y el uso de los resultados, especialmente por parte de equipos no técnicos y responsables institucionales que toman decisiones?

4. Dataset y preparación de datos

4.1. Procedencia y descripción del dataset

El conjunto de datos empleado proviene de Zenodo (repositorio de acceso abierto) ontiene aproximadamente **50.000 registros anonimizados** correspondientes a individuos que participan en programas de salud mental. Se trata de un dataset sintético con fines de investigación y docencia, diseñado para modelar dinámicas de adherencia en contextos clínicos y sociales.

Cada registro representa un individuo con información sociodemográfica (edad, género, ocupación, país), variables clínicas (p. ej., presencia y severidad de condiciones de salud mental, uso de medicación), historial de consultas y hábitos de vida (sueño, trabajo, actividad física, dieta, consumo de alcohol y tabaco, uso de redes sociales). Este volumen de datos es adecuado para aplicar análisis exploratorios, segmentación y simulaciones como las propuestas en este TFM.

4.2 Variables clave y construcción de la variable “Churn”

Entre las variables disponibles en el conjunto de datos, se identificaron algunas especialmente útiles para el análisis:

1. Clínicas: como la presencia de una condición de salud mental (*Mental_Health_Condition*), la gravedad del caso (*Severity*) y el uso de medicación (*Medication_Usage*).
2. Historial de atención: reflejado en la variable *Consultation_History*, que indica si la persona ha tenido consultas médicas previas.
3. Hábitos de vida: incluyendo niveles de estrés, horas de sueño, carga laboral, actividad física, uso de redes sociales, calidad de la dieta, consumo de tabaco y alcohol.
4. Datos demográficos: como edad, género, ocupación y país de residencia.

Dado que el dataset no incluye una variable que indique explícitamente si una persona abandonó el tratamiento, se creó una variable objetivo de abandono (churn) en el *Notebook 01 – Creación de churn y Cohortes descriptivas*, utilizando criterios operativos.

Para este estudio, se considera como abandono ($\text{churn} = 1$) a aquellas personas que han sido diagnosticadas con una condición de salud mental (*Mental_Health_Condition* = *Yes*), pero que no registran ninguna consulta médica posterior (*Consultation_History* = *No*). El resto de los casos, donde sí se observa continuidad asistencial, se codifican como $\text{churn} = 0$.

Aunque esta definición es simplificada, permite aproximarse de forma razonable al fenómeno del abandono y está alineada con enfoques similares en estudios sobre adherencia en salud mental.

4.3 Limitaciones encontradas (predictores dominantes, sesgos, calidad de datos).

Durante el análisis del conjunto de datos se identificaron varias limitaciones que influyeron directamente en las decisiones metodológicas del estudio:

1. Definición operacional del abandono: Como el dataset no incluía una variable específica para indicar si una persona había abandonado el tratamiento, se creó una definición de abandono (*churn*) a partir de ciertas reglas. Sin embargo, esto introduce incertidumbre, ya que no permite diferenciar si la persona abandonó voluntariamente, hizo una pausa temporal o fue derivada a otro servicio.
2. Predictores dominantes: Algunas variables, como *Mental_Health_Condition* y *Consultation_History*, mostraron una relación muy fuerte con el abandono, lo que generó modelos que parecían funcionar bien, pero que en realidad se apoyaban casi exclusivamente en esas dos variables. Esto afectó la capacidad de los modelos para generalizar a nuevos casos.
3. Modelos predictivos con sobreajuste: En el “*Notebook 03_A_Modelización_y_Evaluación_del_Churn*” se probaron varios modelos clásicos de predicción (regresión logística, Random Forest y XGBoost). Aunque las métricas iniciales fueron altas, el análisis posterior reveló que los modelos dependían casi por completo de los predictores dominantes. Esto confirmó un problema de sobreajuste y mostró que no era viable construir un modelo predictivo robusto con los datos disponibles.
4. Falta de variables sociales clave: El dataset no incluía información sobre condiciones socioeconómicas o redes de apoyo social, que según la literatura son factores fundamentales para entender por qué una persona deja un tratamiento.
5. Problemas de calidad y balance en los datos: Algunas variables tenían muchos datos faltantes, como *Severity*, con cerca del 50 % de registros incompletos. Además, variables como *Consultation_History* estaban desbalanceadas, lo que complicó el análisis y la construcción de modelos.

4.4 Transformaciones y preparación para el análisis

El proceso de preparación y análisis de los datos se organizó en varias etapas, cada una documentada en los notebooks del proyecto:

1. Análisis exploratorio inicial (Notebooks 00 y 01): Se realizó la limpieza de datos, análisis de las distribuciones y creación de cohortes descriptivas para identificar patrones generales de abandono.

2. Segmentación de usuarios (Notebook 02): Se recodificaron variables categóricas, se normalizaron variables numéricas y se aplicó el algoritmo *K-means* para identificar perfiles diferenciados de usuarios.
 3. Modelización exploratoria (Notebooks 03_A y 03_B_Churn): Se probaron modelos supervisados como regresión logística, Random Forest y XGBoost. El hallazgo de predictores dominantes llevó a descartar el uso del *churn clásico* como resultado principal.
 4. Simulación de estrategias de retención (Notebook 04_Simulación): Se construyeron escenarios alternativos dentro de las cohortes para estimar el posible impacto de distintas intervenciones mediante simulaciones tipo A/B.
- Preparación para visualización (Notebook 05): Se generaron indicadores clave (KPIs), tablas agregadas y datos resumidos sobre abandono y simulaciones, que fueron exportados para su visualización en Tableau

5. Metodología

Este capítulo presenta de manera estructurada qué se hizo en el proyecto, por qué se tomó cada decisión metodológica y cómo cada etapa se conecta con el objetivo central del TFM: *“Comprender las razones del abandono en programas digitales de salud mental y evaluar estrategias de retención de manera rigurosa y útil para la toma de decisiones.”* Aunque los detalles técnicos más específicos (como el código, la selección de hiperparámetros o pruebas adicionales) se encuentran documentados en los Anexos, aquí se resume el razonamiento y las decisiones clave que guiaron el proceso, siguiendo el flujo de trabajo reflejado en los notebooks del proyecto:

- 5.1 Análisis exploratorio de datos (EDA): Notebook 00
- 5.2 Construcción de cohortes y análisis descriptivo del abandono: Notebook 01
- 5.3 Segmentación de usuarios mediante clustering: Notebook 02
- 5.4 Modelos explicativos exploratorios: Notebooks 03_A_Modelización y 03_B_Análisis_Explicativo
- 5.5 Simulación de estrategias de retención tipo A/B: Notebook 04_Simulación
- 5.6 Preparación de datos para visualización en dashboard: Notebook 05

5.1 Análisis exploratorio (EDA)

El primer paso metodológico consistió en realizar un análisis exploratorio de datos (EDA), cuyo objetivo fue evaluar la calidad, completitud y estructura de la base de datos inicial que serviría de soporte a todo el estudio. Esta fase es crítica en investigaciones aplicadas a programas de salud mental, ya que la solidez de los modelos analíticos depende directamente de la calidad y coherencia de los datos disponibles (Boucher & Raiker, 2024)

Como ya sabemos, el conjunto de datos incluyó 50.000 registros y 17 variables, abarcando dimensiones sociodemográficas, clínicas y de hábitos de vida. Desde el inicio se observó un alto grado de completitud en casi todas las variables: edad, género, nivel de estrés, horas de sueño, hábitos de actividad física y consumo de sustancias no presentaban valores ausentes. La excepción fue la variable Severity, que registró 25.002 valores nulos (50% del total). Este hallazgo la sitúa en un umbral crítico de completitud, ya que en la literatura metodológica se recomienda cautela cuando una variable supera el 40% de datos ausentes: cualquier imputación masiva en este contexto puede introducir sesgos estructurales difíciles de controlar (Hjorth et al., 2016)

[Véase figura: “Porcentaje de Valores Completos por Columna” en Anexo 00_descarga_datos_edu_inicial.]

En el análisis inicial se plantea tres alternativas metodológicas para manejar Severity:

1. Tratar los valores ausentes como categoría propia (“Missing”), reconociendo que la ausencia misma puede reflejar desigualdades en diagnóstico o acceso a servicios.
2. Imputar los valores a partir de correlaciones con otras variables clínicas (como Stress_Level o Mental_Health_Condition), lo cual, aunque viable, implica supuestos fuertes.
3. Excluir la variable de ciertos análisis (por ejemplo, clustering), pero documentando explícitamente las implicaciones de su omisión.

Esta problemática es consistente con estudios internacionales sobre abandono en salud mental, que señalan que la falta de información clínica suele reflejar brechas de acceso o seguimiento desigual según edad, género o nivel socioeconómico.

5.1.1. Estadísticos descriptivos

En las principales variables numéricas se observaron las siguientes medias:

- Edad: 41,5 años (DE 13,8; rango 18–65).
- Horas de sueño: 7,0 (DE 1,7), en línea con recomendaciones médicas.
- Horas de trabajo: 55,1 semanales (DE 14,7), cifra muy superior a la jornada estándar de 40 horas.
- Actividad física: 5 horas semanales (DE 3,2).
- Uso de redes sociales: 3,2 horas diarias (DE 1,6).

Estos indicadores dibujan el perfil de una población adulta laboralmente activa, sometida a altas cargas laborales y con rutinas de sueño ajustadas a estándares, lo que abre interrogantes sobre el papel del trabajo intensivo y la hiperconectividad en el bienestar mental y en el riesgo de abandono de programas. La literatura ha demostrado que la combinación de sobrecarga laboral y

síntomas de estrés es un predictor robusto de deserción tanto en entornos educativos como en programas de salud (Hjorth et al., 2016; Sidana et al., 2023).

[Véase figuras: “Distribution: Age, Sleep hours, Work hours, Physical activity horse y Social Media Usage” en Anexo 00_descarga_datos_edat_inicial).]

5.1.2 Propiedades estadísticas

- Ninguna de las variables numéricas siguió una distribución normal (test de D’Agostino K^2 , $p < 0.05$). Esto obliga a privilegiar métodos no paramétricos en los análisis posteriores.
- No se detectaron outliers extremos bajo el criterio de IQR, lo que facilita comparaciones entre cohortes y reduce la necesidad de transformaciones adicionales.
- Las correlaciones de Spearman entre variables numéricas fueron cercanas a cero, lo que indica independencia relativa entre dimensiones como horas de trabajo, sueño y uso de redes sociales.

5.1.3 Variables categóricas

Las distribuciones de variables como género, ocupación, país, nivel de estrés, dieta, consumo de alcohol/tabaco y uso de medicación resultaron equilibradas, sin categorías marginales con baja representación. Esto constituye una ventaja metodológica para el análisis de cohortes y clustering.

Un hallazgo relevante es que aproximadamente la mitad de los participantes declara tener un diagnóstico de salud mental, y de estos, una proporción considerable hace uso de medicación. A su vez, cerca de la mitad ha tenido consultas previas, lo cual ofrece un indicador indirecto de acceso al sistema de salud.

[Véase figuras: “Frecuencias: Gender, Occupation, County, Mental Health Condition, Severity, Consultation history. Stress level, Diet Quality, Smoking habit, Alcohol consumption y Medication Usage” en Anexo 00_descarga_datos_edat_inicial].]

Desde la perspectiva sociológica, estos datos sugieren que la muestra refleja dinámicas propias de sociedades donde el trabajo intensivo y la hiperconectividad digital conviven con un acceso desigual a la salud mental. La ausencia masiva en Severity podría no ser aleatoria: en estudios similares, los vacíos de información clínica han estado ligados a estigmas, barreras de acceso económico y diferencias de género en el reporte de síntomas, con todo esto confirmamos que:

- El dataset es altamente utilizable para modelización, al no presentar problemas graves de completitud salvo por Severity.
- El manejo de Severity deberá justificarse en cada fase analítica, ya que condiciona la validez de los resultados.

- La independencia entre variables numéricas y las asociaciones débiles pero significativas entre variables clínicas (ej. estrés y sueño, estrés y uso de medicación) sientan las bases para formular hipótesis robustas en torno al abandono.

[Véase figura: “Spearman Correlations (Num↔Num)” en Anexo 00_descarga_datos_eda_inicial.]

En síntesis, el EDA confirma que trabajamos con una base de datos limpia, consistente y estadísticamente adecuada, pero con un reto crítico: la variable Severity, cuya ausencia masiva no puede tratarse solo como un problema técnico, sino como un reflejo de desigualdades estructurales en salud mental.

5.2 Cohortes y análisis descriptivo de abandono

A partir de los hallazgos obtenidos en el análisis exploratorio de datos (EDA), se definió la variable de abandono (*churn*) como el caso en que una persona ha sido diagnosticada con una condición de salud mental (Mental_Health_Condition = Yes), pero no registra ninguna consulta médica posterior (Consultation_History = No). En esos casos, se asigna churn = 1. En cambio, los usuarios con diagnóstico y registro de atención se clasifican como churn = 0.

Esta definición combina tres enfoques complementarios: Desde la sociología de la salud, se interpreta el abandono como una ruptura en el itinerario de cuidado, es decir, personas con una necesidad reconocida que no se mantienen conectadas al sistema. Desde la estadística, se obtiene una variable binaria clara y balanceada, adecuada para análisis comparativos. Desde la ciencia de datos, esta variable permite segmentar a la población en cohortes y construir modelos explicativos más adelante.

5.2.1. Distribución inicial del abandono

Según esta definición, la tasa global de abandono fue del 25,1 %, es decir, uno de cada cuatro usuarios diagnosticados no continuó en el programa. El intervalo de confianza del 95 % (24,7 % – 25,5 %) confirma que se trata de una estimación precisa, respaldada por el gran tamaño muestral. Este hallazgo es clave: revela que una proporción significativa de la población con necesidades de atención no logra establecer continuidad, lo que podría reflejar tanto barreras de acceso como desigualdades en el uso efectivo de los servicios disponibles.

[Véase figura: “Distribución de churn” en Anexo 01_Creación_de_churn_y_Cohortes_descriptivas.]

5.2.2. Tratamiento de valores nulos en la variable Severity

Uno de los principales desafíos metodológicos en el análisis de datos fue el manejo de la variable *Severity*, presentaba un 50 % de valores nulos, lo que representaba un riesgo metodológico importante. Para conservar el tamaño muestral completo ($n = 50.000$) y evitar sesgos, se creó una nueva variable: *Severity_filled*, donde los valores ausentes fueron recodificados como "Unknown".

Este enfoque permitió incluir a quienes no tenían severidad reportada como una cohorte diferenciada, reconociendo que la falta de información puede deberse a barreras en el acceso al diagnóstico o al estigma, más que a un simple error técnico. *Severity_filled* se utilizó como variable de referencia en los análisis de cohortes y en los modelos posteriores.

5.2.3. Construcción de cohortes descriptivas

Para entender mejor cómo se distribuye el abandono, se agruparon los usuarios en cohortes según variables sociodemográficas, clínicas y de estilo de vida. Las categorías se definieron de la siguiente manera:

- Edad (*Age_group*): 18–29, 30–44, 45–59, 60+.
- Horas de sueño (*Sleep_group*): <5h, 5–7h, 7–9h, >9h.
- Horas laborales (*Work_group*): ≤40h, 41–55h, 56–70h, >70h.
- Actividad física semanal (*PA_group*): <2h, 2–5h, 5–8h, >8h.
- Uso de redes sociales (*SM_group*): ≤1h, 1–3h, 3–5h, >5h.
- Otras variables: niveles de estrés, género, país de residencia, y gravedad del diagnóstico (*Severity*), incluyendo una categoría Unknown para valores ausentes.

5.2.4. Resultados descriptivos por cohortes

El análisis mostró que la tasa de abandono se mantiene sorprendentemente estable alrededor del 25 % en casi todas las cohortes, sin diferencias marcadas. Sin embargo, aparecieron algunos patrones sutiles:

- Edad: Los jóvenes de 18–29 años mostraron una tasa ligeramente superior (25,5 %) frente a los mayores de 60 años (24,8 %).
- Sueño: Usuarios que duermen menos de 5 horas presentaron mayor abandono, lo que sugiere una posible relación con la falta de descanso.
- Estrés: Los niveles más altos de estrés se asociaron con un abandono ligeramente superior (25,6 %).
- Actividad física: Las tasas fueron más altas entre quienes reportaban menos de 2 horas de ejercicio semanal.
- Gravedad del diagnóstico: Las diferencias entre categorías fueron mínimas; incluso el grupo con datos desconocidos (*Unknown*) se mantuvo cerca del 25 %.

Estos patrones fueron confirmados mediante pruebas estadísticas (χ^2 y V de Cramér), que indicaron que las asociaciones eran muy débiles ($V < 0,02$), lo que implica que el abandono no se concentra en un grupo específico, sino que se distribuye de forma ampliamente homogénea en la población analizada.

[Véase La tabla: “*chisq_cramers_by_cohort*” y los Heatmaps: “*Tasa de churn por Severity_filled, Stress_Level y Age_group*” en Anexo 01_Creación_de churn_y_Cohortes_descriptivas.]

Los resultados de esta etapa llevan a tres conclusiones clave:

1. El abandono es transversal, afectando de manera similar a usuarios de distintos perfiles demográficos y clínicos.
2. Los factores que muestran mayor potencial explicativo parecen estar relacionados con condiciones de vulnerabilidad psicosocial, como el estrés elevado y la falta de sueño, más que con variables como edad, género o país.
3. La homogeneidad observada entre cohortes justifica avanzar hacia análisis más complejos —como modelos multivariados— que permitan explorar interacciones entre factores de riesgo, lo cual se aborda en las siguientes secciones (5.3 y 5.4).

En general, el análisis de cohortes muestra que el abandono en programas de salud mental no responde a un perfil único, sino que es un fenómeno ampliamente distribuido. Esta evidencia refuerza la necesidad de ir más allá del análisis de variables aisladas y de adoptar enfoques que integren múltiples dimensiones para entender, predecir y eventualmente reducir el abandono.

5.3 Segmentación de usuarios mediante *clustering*

Luego de observar que las tasas de abandono (*churn*) eran bastante homogéneas entre diferentes perfiles, se optó por aplicar un enfoque de segmentación no supervisado, basado en *clustering*. El objetivo fue identificar grupos latentes de usuarios, definidos por sus hábitos, estilos de vida y características sociodemográficas, sin usar la variable *churn* en el entrenamiento. Esto permitió describir perfiles poblacionales y, posteriormente, analizar si estos grupos muestran diferencias en su propensión al abandono.

5.3.1. Preparación de los datos

Para asegurar comparabilidad entre variables de distinta naturaleza, se aplicó un preprocesamiento riguroso:

1. Las variables numéricas (edad, horas de sueño, horas de trabajo, actividad física, uso de redes sociales, razón trabajo/sueño y un índice de riesgo en estilo de vida) fueron escaladas usando **StandardScaler**, para que todas tuvieran un peso equivalente en el análisis.

2. Las variables categóricas (género, país, nivel de estrés y *Severity_filled*) fueron transformadas con **OneHotEncoding**, convirtiendo cada categoría en una variable binaria. Se utilizó la opción *handle_unknown="ignore"* para evitar errores con categorías poco frecuentes.

El resultado fue una matriz numérica estandarizada y lista para aplicar algoritmos de *clustering*.

5.3.2. Determinación del número de clusters

Se aplicaron dos métodos complementarios para decidir cuántos clusters utilizar:

1. El método del codo (Elbow) mostró una caída pronunciada en la inercia hasta $k = 4$, a partir de la cual las mejoras eran marginales. Esto sugiere que cuatro clusters capturan una estructura razonable sin añadir demasiada complejidad.
2. El índice de Silhouette alcanzó su valor más alto en $k = 2$, indicando mayor cohesión interna. Sin embargo, los valores absolutos fueron bajos (todos $< 0,15$), lo que sugiere que los clusters no están claramente separados.

[Véase figuras: "Método del Codo (Elbow)" y "Número de clusters (k)" en Anexo: 02_Segmentación_de Clientes_(Clustering).]

Ante esta ambigüedad, se exploraron ambos escenarios: segmentaciones en 2 y en 4 grupos.

5.3.3. Resultados del clustering

Con 2 clusters:

- *Cluster 0*: Usuarios más jóvenes, con más horas de sueño, mayor actividad física y bajo riesgo en estilo de vida.
- *Cluster 1*: Usuarios de mayor edad, con menos sueño, menos ejercicio, mayor uso de redes sociales y más hábitos de riesgo.

Ambos clusters mostraron tasas similares de abandono (~25 %), lo que indica que, aunque representan estilos de vida opuestos, no se diferencian significativamente en términos de continuidad en el programa.

Con 4 clusters:

- *Cluster 0*: Jóvenes con bajo riesgo general, pero poca actividad física.
- *Cluster 1*: Usuarios con mucho sueño y alto uso de redes sociales.
- *Cluster 2*: Personas con alta carga laboral y poco descanso.
- *Cluster 3*: Adultos mayores con hábitos de riesgo moderado.

En los cuatro casos, las tasas de abandono se mantuvieron cercanas al 25 %, confirmando que, aunque los clusters reflejan perfiles diferenciados, no explican el abandono.

[Véase figuras: “Churn por cluster (k2)” y “Churn por cluster (k4)” en Anexo: 02_Segmentación_de Clientes_(Clustering).]

5.3.4. Validación y limitaciones

El uso combinado de los métodos Elbow y Silhouette indica que entre 2 y 4 clusters es un rango razonable. Sin embargo, el bajo valor del coeficiente de Silhouette ($<0,15$) señala que los grupos tienen fronteras poco definidas. Esto implica que deben entenderse como tipologías suaves, útiles para describir tendencias generales, pero no como agrupamientos estrictos ni predictivos.

Aunque los clusters no permiten predecir el abandono, tienen valor analítico y aplicado:

- Ayudan a caracterizar perfiles de estilo de vida y riesgo, lo cual es relevante para diseñar políticas de salud más ajustadas a las realidades de distintos grupos.
- Sirven para segmentar usuarios en simulaciones A/B, evaluando estrategias de retención según el tipo de usuario.
- Pueden integrarse en modelos explicativos posteriores como variables descriptivas complementarias.

La segmentación por *clustering* permitió identificar grupos socio clínicos dentro de la población, reflejando la diversidad de estilos de vida y condiciones. Sin embargo, estos grupos no explican diferencias significativas en el abandono, lo que reafirma un hallazgo clave del estudio: el *churn* es un fenómeno transversal.

Por ello, los clusters se utilizarán como variables descriptivas, no predictivas, reforzando el giro metodológico hacia enfoques multivariados y simulaciones que integren múltiples dimensiones del riesgo.

5.4 Modelos explicativos exploratorios

Desde el inicio, uno de los objetivos centrales de este TFM fue desarrollar un modelo capaz de predecir el abandono (*churn*) en programas de salud mental y, a partir de ello, evaluar estrategias de retención mediante simulaciones tipo A/B. Con este propósito, se diseñó una secuencia metodológica que incluyó la limpieza y transformación del dataset, el análisis exploratorio (Sección 5.1), la construcción de cohortes descriptivas (Sección 5.2) y la preparación de variables para segmentación y modelado (Sección 5.3).

El momento decisivo se produjo en el “*Notebook 03_A_Modelización_y_Evaluación_del_Churn*”, donde se intentó aplicar modelos supervisados

de *machine learning*. Los resultados de esta prueba fueron tan extremos que llevaron a replantear por completo el enfoque del proyecto.

5.4.1 Modelos predictivos y diagnóstico de viabilidad

En este notebook se exploraron tres modelos de base: regresión logística, Random Forest y Gradient Boosting. Se evaluaron dos versiones del dataset:

- Versión completa (FULL): Los modelos obtuvieron un rendimiento perfecto (ROC-AUC = 1.0; F1 = 1.0), lo que en principio parecería un resultado ideal. Sin embargo, el análisis reveló que esto se debía a una fuga de información (*data leakage*): variables como *Mental_Health_Condition* y *Consultation_History* estaban definidas de forma que casi determinaban el valor de *churn*.
- Versión filtrada (FILTERED): Tras excluir las variables dominantes, el rendimiento cayó drásticamente. Las métricas fueron equivalentes al azar (ROC-AUC \approx 0,50; PR-AUC \approx 0,25), lo que indicó que el resto de variables no aportaban señal predictiva suficiente.

Este hallazgo fue clave: el dataset no permitía construir un modelo predictivo de churn robusto ni útil en la práctica. Aun así, se decidió conservar este notebook como parte del informe metodológico, ya que documenta el rigor con que se descartó un enfoque inapropiado.

[Véase resultados de: “3. Modelado y evaluación para ambos datasets (imputación dentro del pipeline)” en Anexo: 03_A_Modelización_y_Evaluación_del_Churn.]

5.4.2. Transición hacia un modelo explicativo

Ante la inviabilidad del enfoque predictivo, se optó por un cambio de estrategia: aplicar un modelo logit explicativo para explorar qué factores se asocian estadísticamente con el abandono, sin pretender predecir con precisión.

Se transformaron las variables categóricas mediante codificación *one-hot*, seleccionando categorías de referencia con criterio analítico (por ejemplo, *Female* en género, *Low* en nivel de estrés y *Unknown* en severidad). Los coeficientes se interpretan como odds ratios relativos a esas categorías base.

Los resultados mostraron que la mayoría de variables tenían odds ratios cercanos a 1, y sus intervalos de confianza cruzaban esa referencia. Además, los efectos marginales promedio indicaron que los cambios en la probabilidad de abandono eran pequeños y estadísticamente no significativos. El diagnóstico de colinealidad (medido con el índice VIF) descartó problemas técnicos graves, por lo que el modelo era estable, aunque con bajo poder explicativo.

[Véase Figura: “p-values por variable” en Anexo: 03_B_Análisis_Explicativo_con_Regresión_Logística.]

Estos resultados confirman lo observado en etapas anteriores: el abandono es un fenómeno transversal, no concentrado en un grupo específico por edad, género o país. La variable *Severity_filled*, con un 50 % de registros "Unknown", refleja más bien un vacío institucional de diagnóstico que una condición asociada al abandono.

El proyecto fue concebido inicialmente con una orientación hacia la predicción de abandono y simulaciones A/B. Sin embargo, los resultados obtenidos en el “*Notebook 03_A Modelización y Evaluación del Churn*” mostraron de forma clara que un enfoque predictivo no era viable con los datos disponibles.

Este diagnóstico fundamentó un giro estratégico hacia un enfoque explicativo, más útil para comprender el fenómeno del abandono desde una perspectiva multidimensional. El modelo logit confirmó que no existe un perfil único o claro que anticipe el abandono, lo que refuerza la idea de diseñar estrategias de retención más amplias, en lugar de segmentadas por características demográficas simples.

Este cambio de enfoque no solo fortalece la solidez metodológica del TFM, sino que demuestra capacidad crítica para descartar caminos ineficaces y adoptar alternativas más interpretables y útiles. Así, el análisis explicativo, combinado con la segmentación y las simulaciones A/B, aporta un marco riguroso para estudiar un fenómeno complejo como el abandono en salud mental digital.

5.5 Simulación de estrategias de retención mediante A/B Testing

Luego de confirmar que el abandono (*churn*) es un fenómeno transversal, que la segmentación describe estilos de vida, pero no distingue entre quienes abandonan y quienes continúan y que los modelos predictivos no son viables, con este dataset se diseñó una simulación de intervenciones tipo A/B.

El objetivo fue estimar, de manera contrafactual, el efecto que tendrían pequeñas mejoras en hábitos clave —como el sueño, el estrés, el uso de redes sociales o la actividad física— sobre la tasa de abandono. La simulación se basó en el modelo logit explicativo, entrenado sin variables que pudieran generar *leakage*. Para cada escenario, se forzó el cambio en la variable simulada y se estimó la diferencia en la tasa de *churn* respecto a la línea base (25,12 %), con intervalos de confianza del 95 % obtenidos por bootstrap.

5.5.1 Resultados poblacionales de las simulaciones A/B

A nivel general, los efectos de cada intervención aplicada de forma aislada fueron muy pequeños, con diferencias en la tasa de abandono menores a $\pm 0,25$ puntos porcentuales (p.p.):

- Mejorar sueño (<5h → 5–7h): 25,12 % → 24,97 % (–0,15 p.p.)
- Reducir uso de redes (>5h → 3–5h): 25,12 % → 25,20 % (+0,08 p.p.)
- Reducir estrés (High → Medium): 25,12 % → 24,87 % (–0,25 p.p.)

Aunque los intervalos de confianza fueron estrechos, indicando estimaciones estables, en todos los casos incluían el valor cero. Esto confirma que ninguna intervención unitaria, aplicada a toda la población, tiene un impacto práctico relevante en la retención.

[Véase Figuras: “Simulación A/B – cambio esperado en churn (IC95%)” y “Simulación A/B – efectos por escenario” en Anexo: 04_Simulación_de_Experimentos_AB.]

5.5.2 Diseño factorial 2⁴: combinaciones de cambios

Para ampliar el análisis, se aplicó un diseño factorial 2⁴, que combinó la mejora/no mejora en cuatro variables (sueño, estrés, redes sociales, actividad física), generando 16 escenarios de intervención.

- Efectos principales:
 - Estrés: –0,141 p.p.
 - Sueño: –0,076 p.p.
 - Redes sociales: –0,053 p.p.
 - Actividad física: –0,010 p.p.
- Interacciones: Las combinaciones de mejoras no generaron un efecto acumulado mayor al de cada variable por separado. Por ejemplo, mejorar estrés + actividad física tuvo un impacto similar al de reducir solo el estrés. Incluso las combinaciones triples o cuádruples no mostraron efectos relevantes.

A pesar de que algunos resultados fueron estadísticamente significativos la magnitud de los efectos fue demasiado baja para considerarse clínicamente útil o relevante para la gestión del programa.

5.2.3 Análisis de Subcohortes: Estratificación por Niveles de Riesgo

Para explorar si las intervenciones simuladas podrían tener un mayor impacto en grupos particularmente vulnerables, se analizaron dos subcohortes específicas:

- Personas jóvenes (entre 18 y 29 años) con niveles altos de estrés.
- Personas con niveles altos de estrés y menos de cinco horas de sueño por noche.

Los resultados obtenidos en ambos grupos confirmaron lo ya observado a nivel poblacional. Las intervenciones dirigidas a mejorar el sueño o reducir el estrés mostraron efectos modestos, con reducciones en la tasa de abandono que oscilaron entre –0,04 y –0,09 puntos porcentuales (p.p.).

Por su parte, los cambios simulados en actividad física o uso de redes sociales apenas generaron variaciones, con incrementos mínimos de entre +0,01 y +0,02 p.p.

A pesar de que los intervalos de confianza al 95 % fueron estrechos —lo que sugiere estimaciones estables y consistentes—, la magnitud de los efectos fue prácticamente irrelevante desde una perspectiva de gestión o política pública.

Este resultado se visualiza claramente en las visualizaciones: “*Comparativa Δ churn: Población total vs. Subcohorte de riesgo (con IC95%)*” y “*Comparativa Δ churn: subcohorte HighStress_LowSleep vs. población total (IC95%)*” del notebook 04_Simulación_de_Experimentos_AB en anexos.

En ambas visualizaciones, se observa que los efectos en las subcohortes siguen la misma dirección que en la población general, pero no se amplifican de forma significativa. Estos hallazgos refuerzan una conclusión clave de este TFM: incluso en grupos de mayor riesgo, las intervenciones unifactoriales no son suficientes para reducir el abandono de manera relevante. Desde una perspectiva mas social, esto sugiere que el *churn* en programas de salud mental digitales es un fenómeno complejo y multifactorial, vinculado a determinantes estructurales más que a hábitos individuales aislados. Por lo tanto, las estrategias efectivas de retención deberán ser integrales, combinadas y adaptadas a contextos específicos, en lugar de centrarse en modificaciones puntuales de comportamiento.

[Véase Figuras: “*Comparativa de Δ en subcohorte HighStress_Young vs. población total (IC95%)*” y “*Comparativa de Δ en subcohorte HighStress_LowSleep vs. población total (IC95%)*” en Anexo: 04_Simulación_de_Experimentos_AB.]

6.5 Dashboard de resultados: KPIs, visualizaciones y uso orientado a negocio.

Después de completar las fases clave del análisis, el último paso consistió en crear un dashboard interactivo. Su propósito fue sintetizar los hallazgos y facilitar su comprensión para audiencias no técnicas, especialmente equipos directivos o responsables institucionales. El objetivo principal del tablero fue traducir los resultados del análisis en indicadores claros, visuales y accionables. Entre otras funciones, permite monitorizar la tasa de abandono (*churn*) en el programa, explorar diferencias por grupos sociodemográficos o clínicos y visualizar el impacto estimado de distintas estrategias simuladas de retención.

6.5.1 Diseño del dataset para el dashboard

Para la construcción del dashboard, no se utilizó directamente la base original de 50.000 registros ni las cohortes complejas generadas durante el análisis. En su lugar, se preparó un archivo específico y optimizado para visualización:

Nombre del archivo: dataset_aggregated_official.csv

Contenido: métricas agregadas de abandono (tasas de churn, intervalos de confianza, tamaños muestrales), previamente calculadas en Python.

Estructura: formato tabular, liviano y compatible con Tableau.

Diseñado para cargar rápidamente y evitar cálculos complejos en el entorno visual. Esta separación responde a un principio de eficiencia metodológica. El procesamiento estadístico y la validación se realizaron en herramientas como Python, mientras que Tableau se utilizó exclusivamente para presentar los resultados finales, sin realizar cálculos en tiempo real. Así, se garantiza tanto la consistencia de los datos como una experiencia fluida para los usuarios del dashboard.

[Véase Dashboard en Tableau Public:

https://public.tableau.com/app/profile/andrea.buena.o/viz/Dashbord_Abandono_Salud_Mental_TFM/Dashboard]

6.5.2 Visualización final: estructura y propósito del dashboard

El dashboard final (Figura 5.6.1) fue diseñado para ofrecer una síntesis visual clara y accesible de los hallazgos principales del estudio. Integra indicadores clave y representaciones gráficas que permiten tanto una visión ejecutiva general como un análisis detallado por diferentes dimensiones. Cada componente visual aporta una lectura complementaria que facilita la toma de decisiones basada en evidencia. Los gráficos propuestos son los siguientes:

Indicadores clave de desempeño (parte superior central)

En la parte central superior del panel se ubican tres indicadores principales (KPIs), que resumen el estado general del programa:

- **Abandono global:** 23,5 % de los usuarios se encuentran en situación de abandono.
- **Retención global:** 76,5 % se mantienen activos dentro del sistema.
- **Reducción esperada:** mejora estimada de 2,2 % en escenarios de intervención, basada en simulaciones A/B.

Este bloque funciona como una “tarjeta de presentación” para equipos ejecutivos, ya que condensa la información más relevante de manera inmediata y comprensible.

Severidad clínica por grupo etario (parte superior izquierda)

Una tabla cruza la severidad clínica (Alta, Media, Baja, Desconocida) con los grupos de edad (18–29, 30–44, 45–59, 60+). Esto permite observar si existen diferencias sustanciales entre cohortes. El resultado muestra que las variaciones son mínimas, lo que refuerza la idea de que la severidad no es un factor diferenciador claro en el abandono.

Distribución etaria de la muestra (parte central izquierda)

Un gráfico de barras apiladas muestra la proporción de usuarios en cada grupo de edad. Se destaca que la mayoría se concentra entre los 30 y 59 años, lo que contextualiza la representatividad de cada segmento en los análisis posteriores.

Tasa de abandono por género (parte central derecha)

Un gráfico de barras horizontales muestra la tasa de abandono entre hombres, mujeres, personas no binarias y quienes no declararon género. Las diferencias son pequeñas (23–24 %), confirmando lo observado previamente en el análisis de cohortes: el abandono no se concentra en un solo grupo de género.

Tasa de abandono por severidad (debajo del gráfico de género)

Este gráfico representa las tasas de abandono por nivel de severidad clínica. Incluso en el grupo con severidad desconocida ("Unknown"), la tasa se mantiene cercana al 23–24 %. Esto sugiere que la severidad percibida o registrada no determina significativamente la continuidad en el programa.

Tabla comparativa A/B con intervalos de confianza (parte inferior izquierda)

Se presenta una tabla que compara ambos escenarios simulados:

- A (control)
- B (intervención)

Para cada uno se informa la tasa de abandono, el intervalo de confianza al 95 % y el tamaño muestral correspondiente. Esta visualización mantiene la trazabilidad de los métodos descritos en la sección 5.5 y permite revisar la precisión estadística de los resultados.

Gráfico comparativo A vs. B (parte inferior derecha)

Un gráfico de burbujas con líneas de IC95% ilustra de forma intuitiva la diferencia entre los dos brazos simulados. A simple vista se observa que las diferencias son pequeñas, lo que está en línea con los resultados de las simulaciones A/B: ningún cambio individual en hábitos genera una mejora sustancial en la retención.

En conjunto, el dashboard cumple una doble función: sintetiza resultados complejos de manera visualmente accesible y apoya la toma de decisiones estratégicas orientadas a mejorar la retención en programas de salud mental.

7. Discusión

Los resultados del proyecto coinciden con lo documentado en la literatura reciente sobre abandono en programas de salud mental, especialmente en entornos digitales. El abandono (o *churn*) es alto, transversal y multifactorial, y difícilmente puede explicarse por una sola variable

individual. Esta idea se confirma de forma consistente a lo largo del análisis. En la sección 5.1 (EDA) y 5.2 (análisis por cohortes), observamos una tasa de abandono del 25 %, constante a través de edad, género, país y severidad clínica. Aunque hay ligeras variaciones, la mayoría no es estadísticamente significativa. En 5.3 (clustering), los grupos formados reflejan estilos de vida distintos, pero no diferencias relevantes en abandono, la tasa se mantiene cercana al 25 % en todos los casos. En 5.4, los modelos explicativos (logit) confirman esta homogeneidad, los coeficientes son pequeños y los efectos marginales, mínimos. Esto descarta la existencia de predictores individuales fuertes. En 5.5, las simulaciones A/B muestran que, incluso modificando variables clave como el sueño o el estrés, los cambios en abandono son muy reducidos ($\leq \pm 0,25$ puntos porcentuales), tanto a nivel poblacional como en subgrupos de riesgo.

El dashboard final (5.6) traduce estos hallazgos en indicadores ejecutivos claros, permitiendo una lectura accesible de las tasas de abandono y de los efectos estimados de cada intervención, con sus intervalos de confianza. Metodológicamente, este recorrido aporta valor al pasar de un enfoque predictivo —que resultó inviable por problemas de sobreajuste y falta de señal— hacia un enfoque explicativo y de simulación. Este cambio permitió evitar errores comunes en modelos de churn y enfocarse en estimaciones más realistas y útiles para la toma de decisiones.

Desde una mirada sociológica, destaca la homogeneidad del abandono entre perfiles y la gran proporción de datos faltantes en la variable de severidad clínica (50 % “Unknown”), lo cual sugiere limitaciones institucionales en el registro y posibles barreras estructurales (acceso, diagnóstico, estigma). En conjunto, el proyecto muestra que no hay una solución única para reducir el abandono: se trata de un fenómeno complejo que requiere estrategias integradas y análisis contextualizados.

8. Conclusiones y recomendaciones

Principales conclusiones

- El abandono es transversal (~25 %) y no varía sustancialmente por edad, género, país o severidad (5.2). La segmentación tampoco distingue perfiles con mayor riesgo (5.3).
- No se identifican predictores fuertes: los modelos explicativos muestran odds ratios cercanos a 1 (5.4).
- Las intervenciones individuales tienen un impacto limitado: los escenarios A/B generan cambios mínimos en la tasa de abandono, incluso en subgrupos vulnerables (5.5).
- La falta de información en variables clave, como la severidad (con 50 % de valores “Unknown”), limita el poder analítico y evidencia vacíos en el sistema de registro (5.1–5.4).
- El dashboard (5.6) sintetiza estos resultados de forma clara, permitiendo su uso práctico en contextos de gestión y toma de decisiones.

Recomendaciones

- Diseñar estrategias multifactoriales: combinar manejo de estrés, hábitos de sueño, accesibilidad a la primera consulta y seguimiento continuo. Evitar enfoques centrados en una única variable.
- Mejorar la gobernanza de datos: completar y estandarizar el registro de severidad, documentar trayectorias asistenciales completas y causas de abandono.
Evaluar rigurosamente antes de escalar: utilizar diseños A/B reales (o cuasi-experimentales), con intervalos de confianza y análisis por subgrupos.
- Potenciar el uso del dashboard: automatizar alertas y filtros por servicio, grupo etario o periodo para focalizar acciones donde más se necesitan.

9. Limitaciones y trabajo futuro

Este estudio se basó en un conjunto de datos sintéticos y de corte transversal. Esta elección metodológica permitió replicar patrones realistas de abandono descritos en la literatura, asegurando la privacidad y la viabilidad técnica del análisis. Sin embargo, limita la posibilidad de observar cómo evoluciona la retención en el tiempo y reduce la generalización de los resultados a contextos reales. Además, la incompletitud en variables clave —como la severidad clínica, con un 50 % de datos “desconocidos”—, y la ausencia de factores estructurales relevantes (como cobertura del sistema, tiempos de espera o redes de apoyo) pueden estar ocultando diferencias importantes entre perfiles de riesgo.

Para futuras investigaciones, se recomienda validar estos hallazgos con datos reales y longitudinales, que permitan analizar la retención como un proceso dinámico. También sería útil aplicar enfoques causales y técnicas de estimación de heterogeneidad del efecto (por ejemplo, *causal forests*), con el fin de identificar qué estrategias funcionan mejor para distintos grupos de usuarios. Otra línea clave es la integración operativa del dashboard desarrollado en este TFM. Su uso institucional debería incluir actualización periódica, controles de calidad y validación por parte de equipos clínicos. Finalmente, se sugiere mejorar los sistemas de registro en contextos reales, incorporando datos sobre motivos de abandono y puntos críticos del itinerario de atención, desde el diagnóstico hasta el seguimiento.

Referencias

- Abdelhamid,, S. E., Kuhlman, D. C. J., Marathe, P. M. V., Ravi,, P. S. S., & Reid, D. K. (2016, 06 26). Agent-Based Modeling and Simulation of Depression and Its Impact on Student Success and Academic Retention. DOI: 10.18260/p.26545
- Baee, S., Eberle, J. W., Baglione, A. N., Spears, T., Lewis, E., Wang, H., Funk, D. H., Teachman, B., & Barnes, L. E. (2024, Dec). Early Attrition Prediction for Web-Based Interpretation Bias Modification to Reduce Anxious Thinking: A Machine Learning Study. *JMIR Ment Health.*, 20(11). 10.2196/51567
- Baek, J., Boutilier, J. J., Farias, V. F., Jónasson, J. O., & Yoeli, E. (2024, Julio 18). Policy Optimization for Personalized Interventions in Behavioral Health. *Manufacturing & Service Operations Management*, 27(3). <https://doi.org/10.1287/msom.2023.0548>
- Baumel, A., Muench, F., Edan, S., & Kane, J.M. (2019, May 02). Objective User Engagement With Mental Health Apps: Systematic Search and Panel-Based Usage Analysis. *JMIR*, 21(9). 10.2196/14567
- Boucher, E. M., & Raiker, J. S. (2024, August 08). Engagement and retention in digital mental health interventions: a narrative review. *BMC Digital Health*, 2(52). <https://doi.org/10.1186/s44247-024-00105-9>
- Firth, N., Barkham, M., Delgadillo, J., Allery, K., Woodward, J., & O'cathain, A. (2021, November 27). Socioeconomic Deprivation and Dropout from Contemporary Psychological Intervention for Common Mental Disorders: A Systematic Review. *Administration and Policy in Mental Health and Mental Health Services Research*, 49. <https://doi.org/10.1007/s10488-021-01178-8>
- Gratzer, D., & Khalid-Khan, F. (2015, Noviembre 2). Internet-delivered cognitive behavioural therapy in the treatment of psychiatric illness. *CMAJ*, 0. 10.1503/cmaj.150007
- Henzen, A., Moeglin, C., Giannakopoulos, P., & Sentissi, O. (2016, April 09). Determinants of dropout in a community-based mental health crisis centre. *BMC Psychiatry*, 16(111). <https://doi.org/10.1186/s12888-016-0819-4>
- Hjorth, C. F., Bilgrav, L., Frandsen, L. S., Overgaard, C., Torp-Pedersen, C., Nielsen, B., & Bøggild1, H. (2016). Mental health and school dropout across educational levels and genders: a 4.8-year follow-up study. *BMC Public Health*, 11(1). DOI 10.1186/s12889-016-3622-8
- Kirkbride, J. B., Anglin, D. M., Colman, I., Dykxhoorn, J., Jones, P. B., Patalay, P., Pitman, A., Sonesson, E., Steare, T., Wright, T., & Griffiths, S. L. (2024, February). The social determinants of mental health and disorder: evidence, prevention and recommendations. *World Psychiatry*, 23(1). 10.1002/wps.21160.
- Lyons, N., Cooper, C., & Lloyd-Evans, B. (2021, June 23). A systematic review and meta-analysis of group peer support interventions for people experiencing mental health conditions. *BMC Psychiatry*, 21(315). <https://doi.org/10.1186/s12888-021-03321-z>

- Ong, C. W., Lee, E. B., & Twohig, M. P. (2018). A meta-analysis of dropout from psychotherapy. *Journal of Psychotherapy Integration. Behaviour Research and Therapy*, 104(3). doi.org/10.1016/j.brat.2018.02.004.
- Organización Mundial de la Salud. (2025, Septiembre 2). *Más de mil millones de personas padecen trastornos de salud mental: es preciso ampliar urgentemente los servicios*. <https://www.who.int/es/news/item/02-09-2025-over-a-billion-people-living-with-mental-health-conditions-services-require-urgent-scale-up>
- Pandey, B. (2024). Mental Health and Lifestyle Dataset [Data Set]. In *Zenodo*. <https://doi.org/10.5281/zenodo.14838680>
- Reneses, B., Muñoz, E., & Lopez-Ibor, J. J. (2009, Octubre). Factors predicting drop-out in community mental health centres. *World Psychiatry* ., 8. 10.1002/j.2051-5545.2009.tb00246.x.
- Sidana, A., Agrawal, A., & Kaur, J. (2023, May - Aug). Factors Associated with Dropout from Community Mental Health Clinic in Chandigarh during COVID-19 Pandemic. *World Social Psychiatry*, 5(2). 10.4103/wsp.wsp_12_22
- Velazquez, A., Sánchez Sosa, J. J., Lara, M. d. C., & Sentiés, H. (2000). El abandono del tratamiento psiquiátrico motivos y contexto institucional. *Revista de Psicología de la PUCP*, 18(2), 314-340.

ANEXOS:

Anexo 1. Descarga de datos y EDA inicial

Este anexo contiene el proceso de descarga de datos, limpieza preliminar y análisis exploratorio inicial.

[Ver Notebook en HTML](#)

Anexo 2. Creación de churn y cohortes descriptivas

Se describen las cohortes de usuarios y se genera un análisis descriptivo del churn a partir de los datos.

[Ver Notebook en HTML](#)

Anexo 3. Segmentación de clientes (Clustering)

Incluye los experimentos de clustering para segmentar a los clientes en función de variables relevantes.

[Ver Notebook en HTML](#)

Anexo 4. Modelización y evaluación del churn

Notebook con las pruebas de modelización predictiva, métricas de rendimiento y discusión de resultados.

[Ver Notebook en HTML](#)

Anexo 5. Análisis explicativo con regresión logística

Se realiza un análisis explicativo de las variables asociadas al churn mediante regresión logística.

[Ver Notebook en HTML](#)

Anexo 6. Simulación de experimentos A/B

Incluye la simulación de experimentos unifactoriales y multifactoriales para evaluar estrategias de retención.

[Ver Notebook en HTML](#)

Anexo 7. Preparación de datos para dashboard en Tableau

Notebook con el tratamiento y preparación de datos para la construcción de dashboards en Tableau.

[Ver Notebook en HTML](#)

